



PODSTAWY SIECI NEURONOWYCH

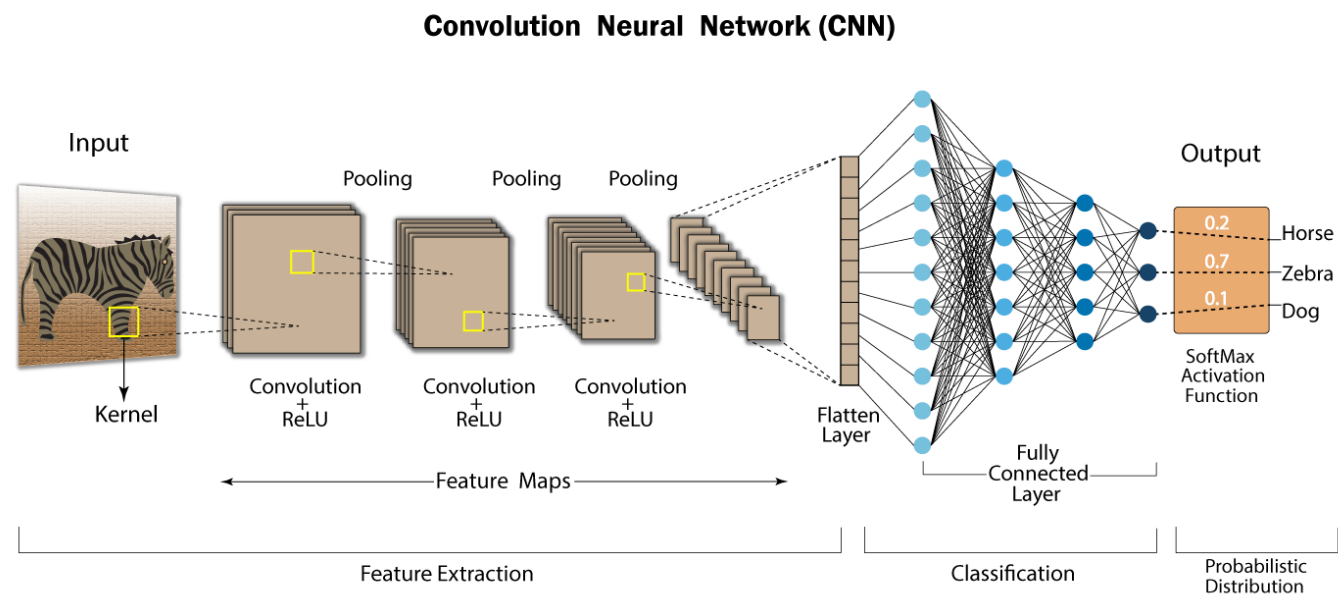
Tobiasz Rolla Piotr Ges

ZDEFINIOWANIE PROBLEMU

- Klasyfikacja kart do gry na podstawie obrazów przy użyciu sieci konwolucyjnej(CNN)
- Klasyfikacja odbywa się w obrębie 53 klas (13 kart z każdego koloru + Jocker)

OPIS DZIAŁANIA SIECI KONWOLUCYJNEJ

- Sieć CNN składa się z warstw
- konwolucyjnej
- poolingowej
- Warstwa w pełni połączona



WARSTWA KONWOLUCYJNA

Celem tej warstwy jest wyodrębnienie szczegółów obrazu poprzez operacji konwolucji(splotu) operacje te wykonuje się poprzez przesuwanie jądra(kernela).

- Padding padding jest techniką pozwalającą zachować rozmiar obrazu

WARSTWA POOLINGOWA

Warstwa ta redukuje rozmiar obrazu przy zachowaniu interesujących szczegółów jej rodzaje to.

- MaxPool największa wartość z kernela zostaje zachowana
- MinPool najmniejsza wartość z kernela zostaje zachowana
- AveragePool liczy średnią wartość dla kernela

WARSTWA W PEŁNI POŁĄCZONA


Warstwa w której każdy z neuronów warstwy jest połączony z każdym neuronem warstwy następnej w sieci.

- Bezpośrednio odpowiada za identyfikacje
- Popularne funkcje aktywacji to ReLU i SoftMax(na wyjściu)

ZESTWA DANYCH

Zestaw danych składa się z 8154 kart zestaw został podzielony na 3 zestawy

- zestaw uczący 7624 kart odpowiadając 93.5%
- walidacyjny zawierał 265 kart odpowiadając 3.25%.
- testowy zawierał również 265 kart odpowiadając 3.25%
- Przeprowadzono również testy innych rozkładów zestawu





PRZYGOTOWANIE OBRAZÓW

- Obrazy przekonwertowane do datasetów
- Załadowane za pomocą dataloaderów
- Przyjęty dla większości testów `batch_size = 32`

UCZENIE MODELU

- Funkcja ucząca dostosowuje parametry modelu.
- Aktualizacja wag za pomocą wstecznej propagacji gradientów.
- Dla każdej pozycji train_loader obliczona jest strata.

```
epoch = 0
done = False
while epoch < num_epochs and not done:
    epoch += 1
    # Training phase
    model.train()
    running_loss, running_corrects = 0.0, 0
    for images, labels in tqdm(train_loader, desc='Training loop'):
        # Move inputs and labels to the device
        images, labels = images.to(device), labels.to(device)

        optimizer.zero_grad()
        outputs = model(images)
        loss = criterion(outputs, labels)
        loss.backward()
        optimizer.step()
        running_loss += loss.item() * labels.size(0)
        _, preds = torch.max(outputs, 1) # Pobieranie prognoz
        running_corrects += (preds == labels).sum().item()
    train_loss = running_loss / len(train_loader.dataset)
    train_accuracy = running_corrects / len(train_loader.dataset)
    train_losses.append(train_loss)
    train_accuracies.append(train_accuracy)
```

FUNKCJA EWAULUJĄCA

Jej celem jest sprawdzenie działania sieci na zbiorze walidacyjnym

- Liczy stratę dla zbioru walidacyjnego

```
# Validation phase
model.eval()
running_loss, running_corrects = 0.0, 0
with torch.no_grad():
    for images, labels in tqdm(val_loader, desc='Validation loop'):
        # Move inputs and labels to the device
        images, labels = images.to(device), labels.to(device)

        outputs = model(images)
        loss = criterion(outputs, labels)
        running_loss += loss.item() * labels.size(0)
        _, preds = torch.max(outputs, 1) # Pobieranie prognoz
        running_corrects += (preds == labels).sum().item()
val_loss = running_loss / len(val_loader.dataset)
val_accuracy = running_corrects / len(val_loader.dataset)
val_losses.append(val_loss)
val_accuaries.append(val_accuracy)
print(f"Epoch {epoch}/{num_epochs} - Train loss: {train_loss:.4f}, Validation loss: {val_loss:.4f}, Train acc: {train_accuracy:.4f}, Val acc: {val_accuracy:.4f}")

# Aktualizacja harmonogramu
#scheduler.step(val_loss)
# Check early stopping criteria
done = es(model, val_loss)
print(f"Early Stopping: {es.status}")
```

WCZESNE ZATRZYMANIE

W celu zapobiegnięciu przeuczeniu zastosowano wsteczne zatrzymanie.

- Jeśli dokładność nie wzrośnie przez n epok
- Model wróci do epoki gdzie nie zauważono spadku strat dokładności

```
class EarlyStopping:
    def __init__(self, patience=5, min_delta=0, restore_best_weights=True):
        self.patience = patience
        self.min_delta = min_delta
        self.restore_best_weights = restore_best_weights
        self.best_model = None
        self.best_loss = float('inf')
        self.counter = 0
        self.status = ""

    def __call__(self, model, val_loss):
        if val_loss < self.best_loss - self.min_delta:
            self.best_loss = val_loss
            self.counter = 0
            self.best_model = copy.deepcopy(model.state_dict())
        else:
            self.counter += 1
            if self.counter >= self.patience:
                self.status = "Stopping training"
                if self.restore_best_weights:
                    model.load_state_dict(self.best_model)
                return True
        self.status = f"{self.counter}/{self.patience}"
        return False
```

SPRAWDZENIE MODELU

W celu sprawdzenia modelu po zakończonym procesie nauki liczy się dokładność na zbiorze testowym.

```
model.eval()
true_labels = []
predicted_labels = []

with torch.no_grad():
    for images, labels in test_loader:
        images, labels = images.to(device), labels.to(device)

        outputs = model(images)
        _, predictions = torch.max(outputs, 1) # Get the class index with the highest probability
        true_labels.extend(labels.cpu().numpy())
        predicted_labels.extend(predictions.cpu().numpy())

# Calculate accuracy
accuracy = accuracy_score(true_labels, predicted_labels)
print(f"Test Accuracy: {accuracy * 100:.2f}%")
```


BADANIE 1

Badanie na sieci składającej się z 6 warstw 2 warstwy kowolucyjnej 2 poolingowe 2 w pełni połączone

```
#Model
class CardClassifier(nn.Module):
    def __init__(self, num_classes=53):
        super(CardClassifier, self).__init__()

        self.conv1 = nn.Conv2d(3, 64, kernel_size=3, stride=1, padding=1)
        self.relu1 = nn.ReLU()
        self.pool1 = nn.MaxPool2d(kernel_size=2, stride=2)


        self.conv2 = nn.Conv2d(64, 128, kernel_size=3, stride=1, padding=1)
        self.relu2 = nn.ReLU()
        self.pool2 = nn.MaxPool2d(kernel_size=2, stride=2)

        self.fc1 = nn.Linear(128 * 32 * 32, 512)
        self.fc2 = nn.Linear(512, num_classes)

    def forward(self, x):


        x = self.pool1(self.relu1(self.conv1(x)))
        x = self.pool2(self.relu2(self.conv2(x)))
        x = x.view(-1, 128*32*32)
        x = F.relu(self.fc1(x))
        output = self.fc2(x)

        return output
```



Confusion Matrix

	ace of clubs	ace of diamonds	ace of hearts	ace of spades	eight of clubs	eight of diamonds	eight of hearts	eight of spades	five of clubs	five of diamonds	five of hearts	five of spades
ace of clubs	13	0	1	0	0	0	0	0	0	0	0	0
ace of diamonds	0	13	0	1	0	0	0	0	0	0	0	0
ace of hearts	0	3	2	0	0	0	0	0	0	0	0	0
ace of spades	0	0	0	5	0	0	0	0	0	0	0	0
eight of clubs	0	0	0	4	0	1	0	0	0	0	0	0
eight of diamonds	0	0	0	0	0	5	0	0	0	0	0	0
eight of hearts	0	0	0	0	0	0	5	0	0	0	0	0
eight of spades	0	0	0	1	0	0	3	0	0	0	0	0
five of clubs	0	0	1	0	0	0	0	4	0	0	0	0
five of diamonds	0	0	0	0	0	0	1	4	0	0	0	0
five of hearts	0	0	0	0	0	0	0	0	5	0	0	0
five of spades	0	0	0	0	0	0	2	0	3	0	0	0





Class Predictions

two of spades
 two of hearts
 two of diamonds
 two of clubs
 three of spades
 three of hearts
 three of diamonds
 three of clubs
 ten of spades
 ten of hearts
 ten of diamonds
 ten of clubs
 six of spades
 six of hearts
 six of diamonds
 six of clubs
 seven of spades
 seven of hearts
 seven of diamonds
 seven of clubs
 queen of spades
 queen of hearts
 queen of diamonds
 queen of clubs
 nine of spades
 nine of hearts
 nine of diamonds
 nine of clubs
 king of spades
 king of hearts
 king of diamonds
 king of clubs
 joker
 jack of spades
 jack of hearts
 jack of diamonds
 jack of clubs
 four of spades
 four of hearts
 four of diamonds
 four of clubs
 five of spades
 five of hearts
 five of diamonds
 five of clubs
 eight of spades
 eight of hearts
 eight of diamonds
 eight of clubs
 ace of spades
 ace of hearts
 ace of diamonds
 ace of clubs



WNIOSKI DO BADANIA 1

Sieć uczyła się bardzo szybko nie będąc odporną na przeuczenie.

- Dokładność 66.04%
- Po 4 epoce nastąpiło przeuczanie

BADANIE 2

W badaniu drugim dodano 3 warstwy

- 1 warstwa konolucyjna
- 1 warstwa poolingowa
- 1 warstwa jednolicie połączona

```
#Model
class CardClassifier(nn.Module):
    def __init__(self, num_classes=53):
        super(CardClassifier, self).__init__()

        self.conv1 = nn.Conv2d(3, 32, kernel_size=3, stride=1, padding=1)

        self.conv2 = nn.Conv2d(32, 64, kernel_size=3, stride=1, padding=1)


        self.conv3 = nn.Conv2d(64, 128, kernel_size=3, stride=1, padding=1)

        self.pool = nn.MaxPool2d(kernel_size=2, stride=2)
        self.fc1 = nn.Linear(128 * 16 * 16, 512)
        self.fc2 = nn.Linear(512, 128)
        self.fc3 = nn.Linear(128, num_classes)

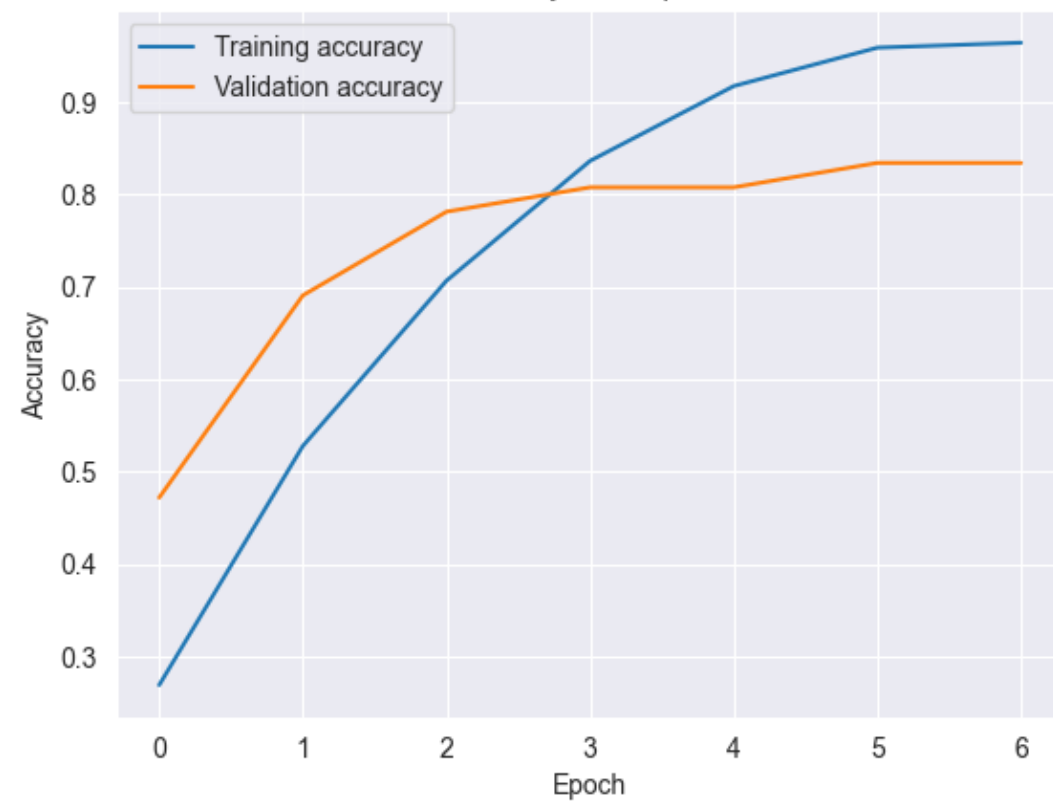
    def forward(self, x):
        x = self.pool(F.relu(self.conv1(x)))
        x = self.pool(F.relu(self.conv2(x)))
        x = self.pool(F.relu(self.conv3(x)))
        x = x.view(x.size(0), -1)
        x = F.relu(self.fc1(x))
        x = F.relu(self.fc2(x))
        output = self.fc3(x)

        return output
```

Loss over epochs




Accuracy over epochs





Class Predictions



WNIOSKI DO BADANIA 2

Dodatkowe warstwy poprawiły dokładność nie zapobiegły przeuczaniu

- Dokładność 80.75%
- Ilość epok przed przeuczeniem 4

BADANIE 3

W 3 modelu dodano:

- Batch Normalisation po każdej warstwie konwolucyjnej
- Zmodyfikowano funkcje Adam o weight-decade


```
#Model
class CardClassifier(nn.Module):
    def __init__(self, num_classes=53):
        super(CardClassifier, self).__init__()

        self.conv1 = nn.Conv2d(3, 32, kernel_size=3, stride=1, padding=1)
        self.bn1 = nn.BatchNorm2d(32)
        self.conv2 = nn.Conv2d(32, 64, kernel_size=3, stride=1, padding=1)
        self.bn2 = nn.BatchNorm2d(64)
        self.conv3 = nn.Conv2d(64, 128, kernel_size=3, stride=1, padding=1)
        self.bn3 = nn.BatchNorm2d(128)
        self.pool = nn.MaxPool2d(kernel_size=2, stride=2)
        self.fc1 = nn.Linear(128 * 16 * 16, 512)
        self.fc2 = nn.Linear(512, 128)
        self.fc3 = nn.Linear(128, num_classes)

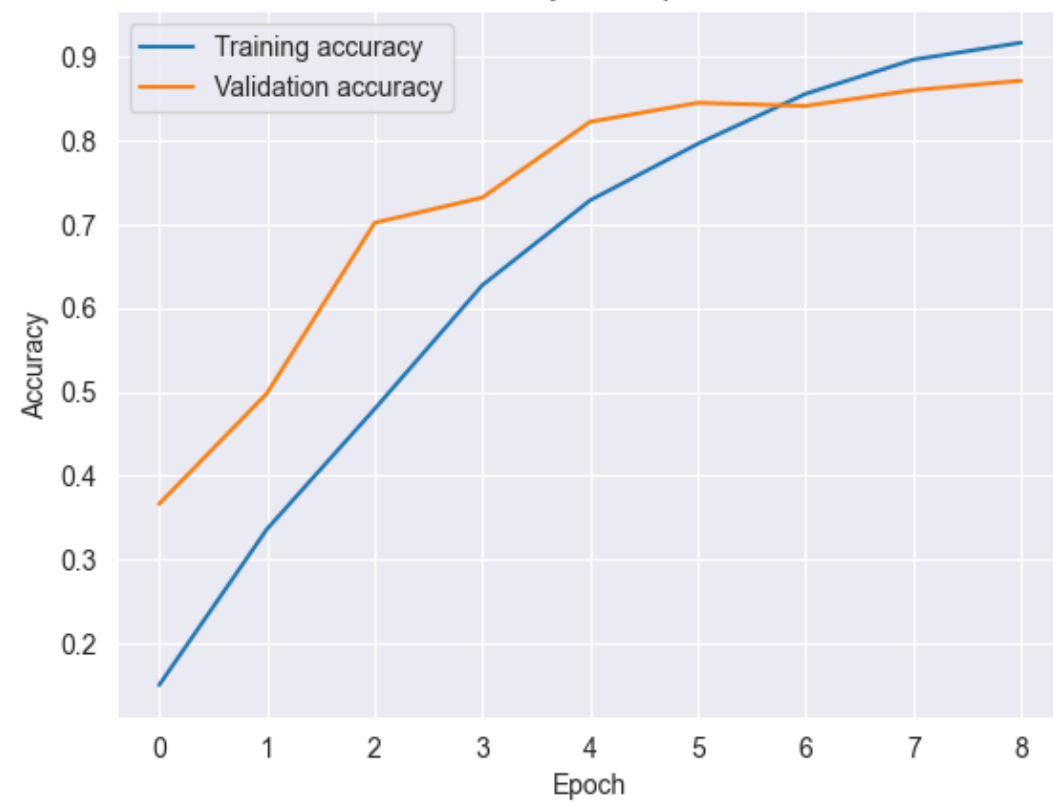
    def forward(self, x):
        x = self.pool(F.relu(self.bn1(self.conv1(x))))
        x = self.pool(F.relu(self.bn2(self.conv2(x))))
        x = self.pool(F.relu(self.bn3(self.conv3(x))))
        x = x.view(x.size(0), -1)
        x = F.relu(self.fc1(x))
        x = F.relu(self.fc2(x))
        output = self.fc3(x)

    return output
```


Loss over epochs



Accuracy over epochs



Confusion Matrix





Class Predictions

two of spades
two of hearts
two of diamonds
two of clubs
three of spades
three of hearts
three of diamonds
three of clubs
ten of spades
ten of hearts
ten of diamonds
ten of clubs
six of spades
six of hearts
six of diamonds
six of clubs
seven of spades
seven of hearts
seven of diamonds
seven of clubs
queen of spades
queen of hearts
queen of diamonds
queen of clubs
nine of spades
nine of hearts
nine of diamonds
nine of clubs
king of spades
king of hearts
king of diamonds
king of clubs
joker
jack of spades
jack of hearts
jack of diamonds
jack of clubs
four of spades
four of hearts
four of diamonds
four of clubs
five of spades
five of hearts
five of diamonds
five of clubs
eight of spades
eight of hearts
eight of diamonds
eight of clubs
ace of spades
ace of hearts
ace of diamonds
ace of clubs

0.0 0.2 0.4 0.6 0.8 1.0
Probability

WNIOSKI DO BADANIA 3

Po wprowadzeniu poprawek sieć jest nadal podatna na przeuczenie jednak w mniejszym stopniu

- Dokładność 84.53%
- Ilość epok przed przeuczeniem 6

BADANIE 4

W 4 modelu zastosowano technikę drop-out w celu zapobiegnięciu przeuczeniu.


```
#Model
class CardClassifier(nn.Module):
    def __init__(self, num_classes=53):
        super(CardClassifier, self).__init__()

        self.conv1 = nn.Conv2d(3, 32, kernel_size=3, stride=1, padding=1)
        self.bn1 = nn.BatchNorm2d(32)
        self.conv2 = nn.Conv2d(32, 64, kernel_size=3, stride=1, padding=1)
        self.bn2 = nn.BatchNorm2d(64)
        self.conv3 = nn.Conv2d(64, 128, kernel_size=3, stride=1, padding=1)
        self.bn3 = nn.BatchNorm2d(128)
        self.pool = nn.MaxPool2d(kernel_size=2, stride=2)
        self.fc1 = nn.Linear(128 * 16 * 16, 512)
        self.fc2 = nn.Linear(512, 128)
        self.fc3 = nn.Linear(128, 64)
        self.fc4 = nn.Linear(64, num_classes)
        self.dropout1 = nn.Dropout(p=0.1)
        self.dropout2 = nn.Dropout(p=0.2)
        self.dropout3 = nn.Dropout(p=0.3)


    def forward(self, x):
        x = self.pool(F.relu(self.bn1(self.conv1(x))))
        x = self.pool(F.relu(self.bn2(self.conv2(x))))
        x = self.pool(F.relu(self.bn3(self.conv3(x))))
        x = x.view(x.size(0), -1)
        x = F.relu(self.fc1(x))
        x = self.dropout1(x)
        x = F.relu(self.fc2(x))
        x = self.dropout2(x)
        x = F.relu(self.fc3(x))
        x = self.dropout3(x)
        output = self.fc4(x)

        return output
```

Loss over epochs




Accuracy over epochs





Class Predictions

two of spades
two of hearts
two of diamonds
two of clubs
three of spades
three of hearts
three of diamonds
three of clubs
ten of spades
ten of hearts
ten of diamonds
ten of clubs
six of spades
six of hearts
six of diamonds
six of clubs
seven of spades
seven of hearts
seven of diamonds
seven of clubs
queen of spades
queen of hearts
queen of diamonds
queen of clubs
nine of spades
nine of hearts
nine of diamonds
nine of clubs
king of spades
king of hearts
king of diamonds
king of clubs
joker
jack of spades
jack of hearts
jack of diamonds
jack of clubs
four of spades
four of hearts
four of diamonds
four of clubs
five of spades
five of hearts
five of diamonds
five of clubs
eight of spades
eight of hearts
eight of diamonds
eight of clubs
ace of spades
ace of hearts
ace of diamonds
ace of clubs



WNIOSKI DO BADANIA 4


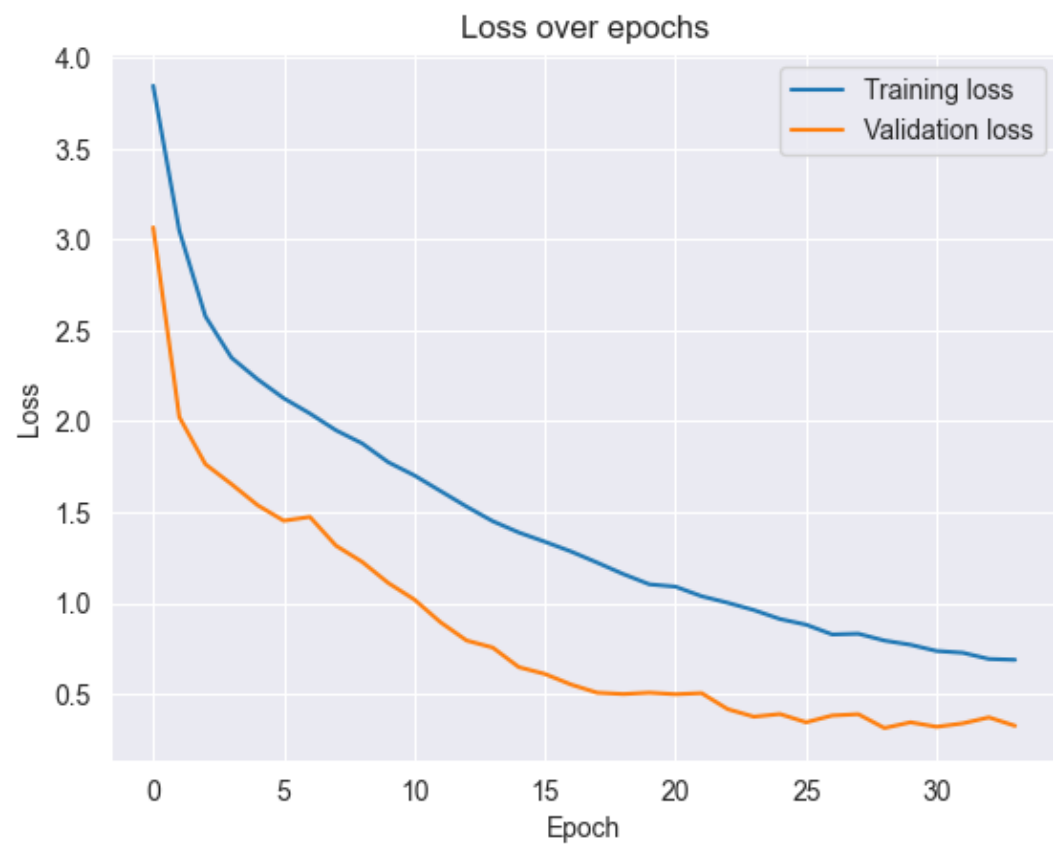
Udało się ograniczyć przeuczenie ponadto wzrosła doładność


- Dokładność 89.91%
- Liczba epok przed przeuczeniem 16

BADANIE 5

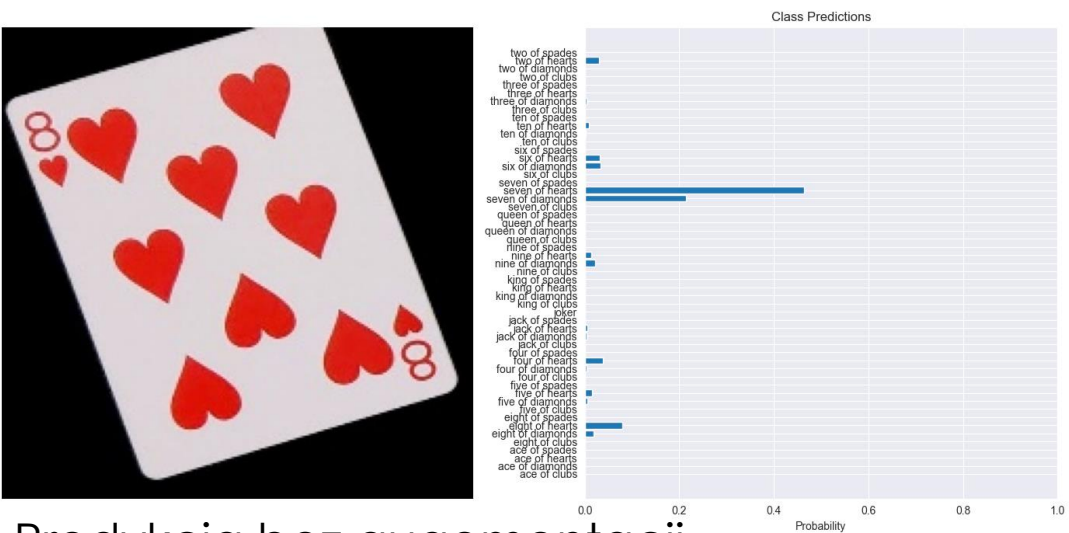
W piątym badaniu dodano augmentacje danych.

- Losowe obracanie obrazów pionowe poziome
- Losowe obracanie obrazów o 30 stopni
- Losowa zmian kolorów obrazu





Predykcja z augementacją



Predykcja bez augementacji

WNIOSKI DO BADANIA 5

Wprowadzenie augmentacji w znaczny sposób zredukowało przeuczenie sieci Ponadto wzrosła dokładność w testach obrazów o niestandardowej strukturze np. obrazy obrócone.

- Dokładność 92.45%
- 27 epok do przeuczenia

BADANIE 6

Ostatnim usprawnieniem było
dodanie dodatkowej warstwy
konwolucyjnej

```
class CardClassifier(nn.Module):
    def __init__(self, num_classes=53):
        super(CardClassifier, self).__init__()

        self.conv1 = nn.Conv2d(3, 32, kernel_size=3, stride=1, padding=1)
        self.bn1 = nn.BatchNorm2d(32)

        self.conv2 = nn.Conv2d(32, 64, kernel_size=3, stride=1, padding=1)
        self.bn2 = nn.BatchNorm2d(64)

        self.conv3 = nn.Conv2d(64, 128, kernel_size=3, stride=1, padding=1)
        self.bn3 = nn.BatchNorm2d(128)

        self.conv4 = nn.Conv2d(128, 256, kernel_size=3, stride=1, padding=1)
        self.bn4 = nn.BatchNorm2d(256)

        self.pool = nn.MaxPool2d(kernel_size=2, stride=2)

        self.fc1 = nn.Linear(256 * 8 * 8, 512)
        self.fc2 = nn.Linear(512, 128)
        self.fc3 = nn.Linear(128, 64)
        self.fc4 = nn.Linear(64, num_classes)


        self.dropout1 = nn.Dropout(p=0.1)
        self.dropout2 = nn.Dropout(p=0.2)
        self.dropout3 = nn.Dropout(p=0.3)

    def forward(self, x):
        x = self.pool(F.gelu(self.bn1(self.conv1(x))))
        x = self.pool(F.gelu(self.bn2(self.conv2(x))))
        x = self.pool(F.gelu(self.bn3(self.conv3(x))))
        x = self.pool(F.gelu(self.bn4(self.conv4(x))))


        x = x.view(x.size(0), -1)
        x = F.gelu(self.fc1(x))
        x = self.dropout1(x)
        x = F.gelu(self.fc2(x))
        x = self.dropout2(x)
        x = F.gelu(self.fc3(x))
        x = self.dropout3(x)

        output = self.fc4(x)
        return output
```


Loss over epochs




Accuracy over epochs





- two of spades
- two of hearts
- two of diamonds
- two of clubs
- three of spades
- three of hearts
- three of diamonds
- three of clubs
- ten of spades
- ten of hearts
- ten of diamonds
- ten of clubs
- six of spades
- six of hearts
- six of diamonds
- six of clubs
- seven of spades
- seven of hearts
- seven of diamonds
- seven of clubs
- queen of spades
- queen of hearts
- queen of diamonds
- queen of clubs
- nine of spades
- nine of hearts
- nine of diamonds
- nine of clubs
- king of spades
- king of hearts
- king of diamonds
- king of clubs
- joker
- jack of spades
- jack of hearts
- jack of diamonds
- jack of clubs
- four of spades
- four of hearts
- four of diamonds
- four of clubs
- five of spades
- five of hearts
- five of diamonds
- five of clubs
- eight of spades
- eight of hearts
- eight of diamonds
- eight of clubs
- ace of spades
- ace of hearts
- ace of diamonds
- ace of clubs

Class Predictions



WNIOSKI DO BADANIA 6

Sieć ta miała najlepsze wyniki.

- Dokładność 95.07%
- 43 epoki do przeuczenia

BADANIE 7

W siódmym badaniu postanowiono zmienić funkcje optymalizacyjne

Optimizer	Adam	AdamW	RMSprop	SGD
Accuracy	95.07%	93.7%	92.83%	85.66%

WNIOSKI DO BADANIA 7

Zmiana algorytmu optymalizacyjnego nie powoduje większych zmian w dokładności wyjątkiem jest SVD.

Adam charakteryzuje się najlepszą dokładnością.

BADANIE 8

W siódmym badaniu postanowiono zmienić proporcje zbioru uczącego zmniejszając zbiór testowy.

Proporcje	60-20-20	70-15-15	80-10-10	bazowy
Accuracy	78.19%	79.47%	85.73%	95.07%



WNIOSKI DO BADANIA 8

Zmniejszanie zbioru uczącego powoduje spadek dokładności sieci

PODSUMOWANIE

- Drop-Out i Argumentacja w pozytywny sposób wpływają na czas uczenia i dokładność
- Dodatkowe warstwy wpływają w niewielki sposób na czas uczenia jednak zwiększają dokładność
- Bach-Normalisation i Weight-Decade w niewielkim stopniu wpływa na czas uczenia jednak zwiększają dokładność
- Zmniejszanie zbioru uczącego negatywnie wpływa na dokładność modelu.
- Algorytm optymalizacyjny Adam najlepiej wpływa na dokładność modelu